

The PDF Capability Atlas

Every document skill, engine, gate and pipeline — mapped, probed, unified

Prepared for: Muhammad Arif bin Fazil (F13 SOVEREIGN)

Prepared by: HERMES · edge bridge, arifOS

Date: Friday, 02 October 2026 · 07:48 MYT

Scope: all PDF-adjacent skills, tools, engines & gates on the federation

Method: live probe + skill-body read + engine self-test

Evidence: OBS (probed now) / DER (inferred from skill bodies)

Isi Kandungan

1 · Kenapa atlas ini wujud	3
2 · Peta 13 skill PDF	3
3 · 5 enjin render (disemak langsung)	4
4 · Paip 7-lapis docforge	5
5 · Kad rujukan: kerja apa → skill apa	6
6 · Sisipan kod — 4 corak berfungsi	7
7 · Lapisan visual & analitik data	8
8 · Gerbang pengesahan (sebelum hantar)	9
9 · Jurang & peluang mengeras	10

1 · Kenapa atlas ini wujud

Federation ini ada **13 skill** yang menyentuh output dokumen, **5 enjin render**, dan satu paip kanonik ([docforge](#)) — tetapi tiada satu peta yang menghubungkannya. Setiap kali kerja dokumen bermula, ia mula dari sifar dan lupa gerbang berbeza setiap kali. Dokumen yang terlepas bukan kerana isi salah — kerana satu gerbang di-skip.

Atlas ini menjawab satu soalan: "**kalau aku nak hasil X, apa jalan paling lurus, dan gerbang mana yang tak boleh dilangkau?**" Ia bukan cadangan skill baru. Ia peta untuk yang sedia ada. Tiada skill baru, tiada tool baru — hanya peta yang hilang.

Masalah manusia yang diselesaikan: Arif tak perlu ingat nama 13 skill. Dia sebut output yang dia nak; peta ini beritahu jalan. Satu masalah, satu peta, satu jalan.

2 · Peta 13 skill PDF

Skill	Peranan	Enjin	Kematangan
document-pipeline	ROUTER — pintu masuk semua kerja dokumen	semua 5	LIVE
forge-pdf-delivery	Paip markdown → HTML → PDF + gerbang	weasyprint	LIVE
scientific-pdf-generation	4 mod: akademik / dossier / sell-side / trading	weasy+reportlab	LIVE
civic-intelligence-pdf	Briefing berwarna, 60 saat scan	weasyprint	LIVE
wop-invoice-generator	Invoice satu muka WOP Sdn Bhd	weasyprint	MID
nano-pdf	Edit teks dalam PDF sedia ada	nano-pdf CLI	LOW
ocr-and-documents	Baca teks dari PDF/scan (pymupdf/marker)	pymupdf marker	MID
forge-document-intelligence	EMD: VLM → gerbang 555-ASI-VISION → provenance	VLM+gate	LIVE
medical-document-interpretation	Tafsir dokumen perubatan MS ke BM	vision_analyze	MID
aaa-pdf-voice-protocol	Tukar jargon dalaman → prosa manusia	translator	MID
powerpoint	Buat/baca .pptx → PDF via soffice	python-pptx	MID
open-slide-integration	Corak penulisan slaid/PDF (6 eureka)	React/Vite	LOW
documentary-biography-from-chat	Biografi/dokumentari dari log chat	weasyprint	MID

Figure 1 — 13 PDF skills, mode & depth




Figure 1 — 13 skill PDF mengikut peranan & kedalaman. Bar biru = kematangan tinggi, merah = pertengahan, kelabu = rendah.


3 · 5 enjin render — disemak langsung

Disemak pada 02 Okt 2026, 07:42 MYT melalui `python3 -m docforge engines`. Bukan andaian — probing langsung.

Enjin	Status	Versi	Keupayaan	Bila guna
chromium	OK	153.0.8010.36	JS, scripting, offline	Fidelity tertinggi; laporan HTML + jadual
typst	OK	0.13.1	paged-media, scripting	Dokumen teks-padat, laju, moden
reportlab	OK	5.0.1	scripting, programmatic	Kawalan canvas, sisip plot
pandoc	OK	3.1.11.1	md → html (tak baca PDF)	Pra-proses markdown
weasyprint	CLI-only	70.0 (CLI)	paged-media, offline	CSS-paged: @page header/footer

Temuan penting (OBS): `/usr/local/bin/weasyprint` versi 70.0 berfungsi sebagai CLI, tetapi `import weasyprint` gagal dalam venv Hermes. Ini bermakna: guna weasyprint melalui shell, bukan dalam skrip Python venv — atau guna chromium/typst/reportlab yang import bersih. Dokumen ini sendiri dihasilkan dengan weasyprint CLI.

Figure 2 — engine inventory
(probed 02 Okt 2026, 07:42 MYT)



Bacaan cepat

- 4/5 enjin import bersih dari Python
- 1/5 (weasyprint) hanya melalui CLI
- **chromium** = pilihan paling selamat (JS + offline)
- **typst** = terpanjang untuk teks-padat
- **reportlab** = satu-satunya untuk kawalan koordinat tepat

4 · Paip 7-lapis docforge (kanonik)

Setiap kerja dokumen melalui 7 lapis, setiap lapis ada pemilik. Jangan duplikasi doktrin pemilik di tempat lain.

#	Lapis	Pemilik	Output
1	Audience	human-facing-artifact-design	Siapa baca, apa mesti diingat
2	Content	auditable-numeric-artifacts	Sumber, angka, tag epistemik
3	Layout	paged-media-report-layout	Paginasi, page-break
4	Render	document-pipeline + docbuild.py	PDF mentah
5	Audit	rendered-document-audit	Bukti kandungan sampai & legible
6	Seal	sealed-deliverable-provenance	Hash kandungan + artifact
7	Deliver	visual-artifact-delivery	MEDIA: ke chat

Perintah satu-baris

```
# render → kira muka → sapu dakwat → lapisan teks → semak laluan-bocor → hash → segel
python3 /root/AAA/scripts/docforge/cli.py build spec.json

# hanya semak gerbang pada PDF sedia ada
python3 /root/AAA/scripts/docforge/cli.py gates out.pdf

# apa yang boleh render SEKARANG (probe langsung)
python3 -m docforge engines --selftest
```

Undang-undang gerbang: build jalankan rantai gerbang SEBELUM ia segel. Dokumen yang gagal gerbang tidak disegel — ia ditinggalkan di disk dengan laporan kegagalan. Segel atas artifact rosak = mencuci defect ke rekod kekal.

5 · Kad rujukan: kerja apa → skill apa

Kalau Arif minta...	Skill	Enjin
"Briefing pagi, PDF"	arif-daily-sensorium + forge-pdf-delivery	weasyprint (plain)
"Laporan petro/sell-side"	scientific-pdf-generation Mod C	weasyprint+matplotlib
"Dossier intel / impress orang"	scientific-pdf-generation Mod B	reportlab/weasyprint
"Briefing sivik berwarna"	civic-intelligence-pdf	weasyprint
"Invoice"	wop-invoice-generator	weasyprint
"Edit PDF ni"	nano-pdf	nano-pdf CLI
"Baca PDF ni"	ocr-and-documents	pymupdf/marker
"Dokumen perubatan, tafsir"	medical-document-interpretation	vision_analyze
"Slaid / deck"	powerpoint	python-pptx → soffice
"Biografi dari chat"	documentary-biography-from-chat	weasyprint

Peraturan pilihan: plain typography = DEFAULT (Arif: *"I hate black dark background in pdf"*). Track imej/dark hanya bila untuk ditunjuk kepada pihak ketiga. Bila ragu — render plain dahulu.

Skop 4-soalan (sebelum tulis kod)

1. **Mod** — akademik / dossier / sell-side / trading / biografi

2. **Bilangan muka** — 5–10 pendek / 11–20 standard / 21–30 dalam
3. **Bilangan figure** — 0–3 ringan / 4–8 standard / 9+ berat
4. **Ketegasan epistemik** — santai / standard / ketat (setiap klaim bersumber)

6 · Sisipan kod — 4 corak berfungsi

Corak 1 — Paip laju: HTML → PDF

```
# tulis HTML dengan CSS inline, render, sahkan, hantar
from weasyprint import HTML # atau: weasyprint in.html out.pdf (CLI)
HTML(filename='brief.html').write_pdf('brief.pdf')

# gerbang wajib: pastikan ia PDF sebenar, bukan teks bertukar sambungan
# $ file brief.pdf → "PDF document, version 1.7"
# $ pdftinfo brief.pdf | grep Pages → bilangan muka == design
```

Corak 2 — Figure matplotlib ke dalam PDF

```
import matplotlib; matplotlib.use('Agg')
import matplotlib.pyplot as plt

fig, ax = plt.subplots(figsize=(7.2, 2.6), dpi=180)
fig.patch.set_facecolor('white') # track plain: latar putih
ax.barh(labels, values, color='#1a3a5c')
plt.savefig('fig1.png', dpi=180, bbox_inches='tight')

# sisip dalam HTML:  (fail se-dir dengan HTML)
```

Corak 3 — Gerbang audit tanpa vision

```
# halaman kosong / pecah = penyebab #1 dokumen gagal
pdftoppm -png -r 110 out.pdf /tmp/qa/page
python3 - <<'EOF'
import glob; from PIL import Image
for f in sorted(glob.glob('/tmp/qa/page-*.png')):
    im = Image.open(f).convert('L'); w,h = im.size; px = im.load()
    dark = tot = 0
    for y in range(0,h,3):
        for x in range(0,w,3):
            tot += 1
            if px[x,y] < 235: dark += 1
    print(f, f"{100*dark/tot:5.2f}%") # <2% = halaman pecah
EOF
```

Corak 4 — EMD: baca dokumen, bukan percaya buta

```
# setiap ekstraksi VLM = teks tak dipercayai dari piksel
# ia mesti melalui gerbang sebelum masuk penaakulan
aaa_ocr doc.pdf --engine qwen25_vl --financial
# → 555-ASI-VISION gate (F12 suntikan + F9 anti-hantu + F2 kebenaran)
# → kontrak OBS · DER · KEYAKINAN · F9 · F12
# → 333-AGI taakul pada teks bergerbang SAHAJA
```

Prinsip: *You pay for OCR once. You pay for bad OCR forever.* OCR bersih tapi salah digit lebih bahaya dari OCR kotor — sebab saluran governance mempercayai output bersih.

7 · Lapisan visual & analitik data

Setiap briefing/dossier mesti ada analitik visual bila data menyokong. Ini bukan hiasan — ia gerbang supaya pembaca boleh scan 3 signal teratas dalam 60 saat.

Bentuk data	Jenis carta	Pustaka
Perbandingan kategori	Bar melintang/menegak	matplotlib
Trend masa	Carta garis (paksi tunggal/kembar)	matplotlib
Bahagian-dari-keseluruhan	Donut (bukan pai — lebih bersih)	matplotlib
Taburan geografi / zon risiko	Peta statik + penanda + zon	cartopy
Aliran keputusan / rantai kesan	Graf berarah	graphviz
Candlestick / isyarat dagangan	Carta OHLC + EMA	reportlab+matplotlib




Figure 3 — routing flow (suffix → engine → pdf)

Figure 3 — aliran penghalaan: bentuk input → enjin → PDF. Satu daripada 5 laluan setiap dokumen.

Peraturan reka analitik

- Latar putih (`facecolor='white'`) — padan track plain
- Palet warna padan signal: hijau `#16a34a` baik, amber `#d97706` perhatian, merah `#dc2626` kritikal, biru `#2563eb` info
- Maks 2 carta bersebelahan; setiap carta mesti ada caption
- `page-break-inside: avoid` pada semua bekas carta
- Dalam rajah matplotlib: letak SEMUA teks dalam koordinat data, jangan `set_aspect('equal')` untuk infografik

Perangkap (terbukti): `transform=ax.transAxes + set_aspect('equal')` = semua teks lesap senyap. PNG render dengan latar & bentuk utuh tapi SIFAR teks. Guna koordinat data; simpan tanpa `bbox_inches='tight'`.

Analitik data lanjutan

Lapisan	Alat	Bila
SQL kolumnar atas Parquet/CSV/LAS	duckdb-analytics-engine	Data besar, pertanyaan analitik
Nombor boleh diperiksa	auditable-numeric-artifacts	Setiap angka load-bearing
Carta sejarah harga / ticker mati	financial-history-charting	Saham/komoditi
Figure geologi berphysics	geological-figure-production	GEOX, Sclater-Christie

8 · Gerbang pengesahan (sebelum hantar)

Setiap gerbang ini telah menangkap defect sebenar dalam sesi lepas. Ia bukan teori.

#	Gerbang	Perintah	Tangkap apa
1	Fail sebenar	<code>file out.pdf</code>	Teks bertukar sambungan palsu
2	Bilangan muka	<code>pdfinfo grep Pages</code>	Overflow senyap (12 slaid → 24 muka)
3	Sapu dakwat	<code>pdftoppm + PIL loop</code>	Halaman kosong / pecah
4	Lapisan teks	<code>pdftotext -f N -l N</code>	Render gagal / imej hilang
5	Bocor laluan	<code>pdftotext grep -c 'file://'</code>	Laluan mesin dalam PDF pihak ketiga
6	Hash	<code>content + artifact SHA256</code>	Artifact tak boleh dibina semula
7	Purge hiasan pelayar	<code>--no-pdf-header-footer</code>	Titik masa render + tajuk dokumen

Ujian tunggal: Dokumen dinyatakan SIAP hanya bila artifact berjalan menepati janji. Exit code bersih bukan bukti — header `%PDF-`, bilangan muka, dan sapu dakwat adalah bukti.

Perangkap yang berulang

- **Page-break paksa per seksyen** = punca #1 halaman hampir-kosong. Biar enjin paginate; simpan satu break untuk kulit.
- **Tampal PDF** bukan sumber = tak boleh dibina semula, sembunyi diagnosis.
- **Gambar yang bawa teks** — model imej render huruf jadi glyph garbled. Text-bearing = render deterministik.
- **weasyprint `box-shadow` diabaikan senyap** — jangan guna; guna border.
- **Emoji tak render dalam font PDF** — ganti dengan label teks (CRITICAL, WARNING, POSITIVE).

9 · Jurang & peluang mengeras

Berikut adalah apa yang peta dedahkan — bukan cadangan skill baru, tetapi kerja mengeras ke atas yang sedia ada.

A. Jurang sebenar (OBS)

Jurang	Kesan	Harden (tanpa skill baru)
weasyprint import gagal dalam venv Python	Skrip Python gagal senyap	Piawai: panggil weasyprint melalui CLI; atau guna chromium/typst/reportlab
docforge di <code>/root/AAA/scripts</code> , bukan pakej	Tak import dari mana-mana	Dokumentasi laluan + alias; pertimbang pasang editable
Dua lane briefing wujud (docforge vs briefing-system retired)	Risiko dua PDF, dua DM	Senarai cron dulu; semak timeslot sebelum tambah job
Track dark vs plain tidak dipaksa	Re-prompt "no need fancy"	Default plain kekal; tanya panjang/pendek di intake
Gerbang bergantung pada ingatan	Skip pada edisi tergesa	Letak gerbang dalam skrip build, exit non-zero

B. Yang sudah kuat (jangan sentuh)

- **SEO/dark/light theme** — civic-intelligence-pdf & scientific-pdf-generation sudah matur
- **Gerbang EMD** — forge-document-intelligence gerbang 555-ASI-VISION kekal arsitektur
- **Track plain** — forge-pdf-delivery CSS skeleton sudah betul
- **Empat mod sci-pdf (A/B/C/D/E)** — pilih ikut audience, bukan topik

C. Pengerasan kecil, kesan besar

1. **Satu alias** `pdfbuild` → docforge build; kurangkan geseran satu perintah.
2. **Satu gerbang pra-hantar** dalam skrip — 7 semakan jadual di atas jadi satu panggilan.
3. **Pengesahan track** di intake: plain vs imej ditanya, bukan diandaikan.
4. **Figure budget** dikira sebelum render (1 figure / 2 muka; max 2000 aksara/muka).

Metrik sebenar: *HumanLeverage = Kegunaan / Perhatian Manusia*. Atlas ini berguna hanya jika ia mengurangkan soalan "yang mana satu?" — bukan menambah satu dokumen untuk dibaca.

Sumber: Body 13 skill (dibaca 02 Okt 2026) · probing enjin langsung `docforge engines` · 07:42 MYT · gerbang terbukti dari sesi 2026-07 s/d 2026-09 · CSS skeleton forge-pdf-delivery · docforge cli.py head.

Tag epistemik: OBS = disemak langsung; DER = disimpul dari body skill.

DITEMPA BUKAN DIBERI