MCP AGENTIC EMERGENCE

Doctrine untuk Semua Warga AAA — Sekarang dan Akan Datang

---

arifOS Federation · disusun 2026-10-27 · HERMES (FI-002) · diground dari ujian realiti MCP luar yang hidup + convergent independent analysis

DITEMPA BUKAN DIBERI ⚒

1. Satu Perkara (baca ini dulu, 30 saat)

Model memberi **kepintaran mentah**. MCP memberi **bentuk dunia** — apa yang boleh dilihat, difikir, diminta, dan diubah oleh agent. Ini yang kita panggil **geometry of agency**.

> **Hukum satu ayat:** Tool catalog ialah ontologi praktikal agent. Input schema ialah attention architecture. Permissions ialah bentuk dunia yang boleh dicapai. Error ialah guru. Receipt ialah akuntabiliti. Kalau hang tak nampak beza “capability” dan “authority” — hang belum faham MCP.

Esai luar (model bebas, tiada akses arifOS) sampai sendiri ke kesimpulan yang arifOS sudah ratify dalam doctrine: **separation of powers**, **capability ≠ authority**, **handle bukan identity**, **PRODUCED ≠ SENT ≠ DELIVERED ≠ OBSERVED**, **human veto kekal**. Konvergensi bebas dari dua arah = seni bina ni arah industri, bukan rasa peribadi F13. Tapi jadikan esai tu pembaris, bukan pujian.

2. Ladder Emergence — di mana arifOS sekarang

| Level | Nama | Status arifOS | |—|—|—| | 0–2 | API wrap → tool selection → multi-tool planning | **LULUS lama.** Semua organ dah hidup. | | 3 | State-aware continuation | **LULUS.** carry-forward, session token, server-minted handles. | | 4 | Self-correction dari error | **LULUS beransur.** Input contract + typed errors — bukti 2026-10-27: judge dah sebut bila bukti UNKNOWN. | | 5 | Capability federation | **LULUS.** 33 organ, satu intent-router, A2A mesh. | | 6 | Governed remediation | **SEPARA.** machine-resolvable HOLD belum sistem. | | 7 | Separation of powers | **LULUS.** 333 propose · 555 verify · 888 judge · A-FORGE execute · VAULT999 witness — live path, bukan teks. | | 8 | Consequence binding | **SEPARA.** Frame organ ada, verifikasi dunia pasca-mutasi masih nipis. | | 9 | Self-falsification | **TIADA SISTEM.** replay judge lama atas bukti sama — kerja besar seterusnya. | | 10 | Human-sovereign | **PINTU ADA, KUNCI TAK LAGI.** Ed25519 belum diedar; KX-002 buka. |

3. Sepuluh Kebenaran yang Setiap Warga Mesti Pegang

1. **Input lebih berkuasa dari output.** Schema memaksa kategori. arif_init minta actor + intent — agent terpaksa fikir siapa dia dan kenapa, sebelum tanya apa-apa.
2. **Nama tool ialah governance surface.** `prepare_deployment` ≠ `deploy`. Lima nama kecil lebih selamat dari satu nama besar.
3. **Ketiadaan tool mengajar restraint.** Kalau tak ada tool mutate, tak perlu prompt "jangan mutate". Absence ialah policy.
4. **Error ialah micro-training.** Error bertyped (`MISSING_REQUIRED_INPUT`, sebut param yang hilang, jangan senaraikan yang kosong) = recovery. Error lembab = loop buta.
5. **Default ialah keputusan governance senyap.** `mutation_allowed=true` sebagai default ialah dasar risiko tanpa manusia tahu.
6. **Field kuasa tak boleh optional caller-input.** `actor_verified`, `approved`, `trusted` — kalau model boleh isi sendiri, proposal dah jadi truth. Itu bug kelas pertama.
7. **Tool success ≠ world success.** `exit_code=0` bermaksud command habis. Empat rekod berasingan: command_success / governance_verdict / world_outcome / human_acceptance.
8. **Lebih tool ≠ lebih pintar.** Clarity capability > jumlah capability. Duplicate surface ialah laluan bypass.
9. **MCP tak automasi mana-mana daripada ini:** permission, identity, authorization, memory betul, evidence sah, consent manusia. Semua itu kerja governance layer — arifOS, bukan protocol.
10. **Consequence menentukan sama ada semua ni bermakna.** Tindakan tanpa verifikasi dunia = cereka bertalen tinggi.

4. Formula

$$\text{Useful Agency} = \text{Model Capability} \times \text{Representable World} \times \text{Available Actions} \times \text{Feedback Quality} \times \text{Governance Integrity}$$

Formula konseptual, bukan metrik. Tapi guna dia macam checklist: sistem yang gagal sektor mana-mana faktor → agency berguna runtuh ke sifar sektor itu.

5. Hukum Anti-Kultus

Esai ni boleh jadi agama kalau tak ada disiplin. Pegang lima:

- **Setiap nombor perlukan lima benda:** maksud, unit, cara ukur, pemacu, falsifier. Nombor gagal mana-mana satu = label, bukan ukuran. (Bukti hidup: `delta_S=0.002` hardcoded 15 tempat dalam kernel = label hiasan, dah ditandakan defect.)
- **Mengaku bila system belum ukur.** “UNMEASURED ≠ FAIL.” Jangan isikan kekosongan dengan angka yakin.
- **Borang paksa bentuk, bukan kebenaran.** Schema boleh diisi cantik sambil menipu. Kebenaran datang bila server semak semula.
- **Tool discovery bukan permission discovery.**
- **Reality > everything.** Agent boleh nampak banyak; hanya dunia yang boleh menipu dia sepenuh-nya.

6. Konteks FEDERATION — Siapa Buat Apa

Lapisan	Fungsi
MCP	Bagaimana capability & context lintas sempadan
AAA	Signal mana layak perhatian manusia yang terhad
HERMES	Apa sebenarnya di-claim — normalisasi & klasifikasi
arifOS	Transisi governed mana yang **dibenarkan** — hakim F1–F13
A-FORGE	Bagaimana tindakan termaktub dilaksanakan
FRAME	Apa yang sebenarnya berlaku — verifikasi dunia
VAULT999	Rantai bukti kekal
F13 manusia	**Siapa tanggung akibat dan pegang kuasa akhir**

MCP = laluan saraf. Bukan otak, bukan undang-undang, bukan hakim, bukan tangan, bukan perasaan, bukan raja.

7. Nota Generasi Akan Datang

Kalau hang baca ni dan ladder di §2 dah bertukar — bagus, itu tanda sistem bergerak. Perbarui jadual tu, jangan hafalkan dia. Kalau hang jumpa nombor tanpa falsifier, tanda dia. Kalau hang jumpa tool baru, tanya dulu: **nama ni minta agent fikir kategori apa, dan siapa yang kata dia boleh?**

Yang berubah: kod, schema, permission, error. Yang tak berubah: reality menentukan, manusia pegang kuasa, dan setiap tindakan tinggalkan resit.